PROJET Machine Learning

CreditSmart Analytics

Prédiction du Montant de Crédit & Détection du Risque de Défaut Bancaire

Formateur	**SALHI Abderrahman**
Module	Machine Learning
Dataset fourni	credits_bancaires.csv
Domaine	Banking & Finance — Credit Risk
Parties couvertes	EDA | Preprocessing | Regression | Classification

"Dans le secteur bancaire, un mauvais modèle de crédit peut coûter des millions. La data science est devenue le bouclier des banques modernes."

1. CONTEXTE DU PROJET

Le secteur bancaire est l'un des domaines les plus transformés par le Machine Learning. L'octroi de crédit, qui était autrefois basé sur l'intuition des conseillers et quelques règles fixes, repose aujourd'hui de plus en plus sur des modèles prédictifs capables d'analyser des dizaines de variables simultanément pour évaluer la solvabilité d'un client.

Vous êtes recruté(e) par **CreditSmart Analytics**, une fintech marocaine qui développe des solutions d'intelligence artificielle pour les banques et les organismes de microfinance. Votre mission est d'analyser un dataset de **612 demandes de crédit** issues de plusieurs agences bancaires au Maroc, afin de construire deux modèles complémentaires :

- Un modèle de régression pour estimer le montant optimal de crédit à accorder selon le profil du demandeur.
- Un modèle de classification pour prédire si un client présente un risque de défaut de paiement.

Ces deux outils permettront à la banque de **prendre des décisions de crédit plus rapides, plus objectives et moins risquées**, tout en réduisant les pertes liées aux mauvaises créances.

Pourquoi ce projet est-il stratégique ?

Le risque de crédit est l'une des principales causes de faillite bancaire dans le monde.

Au Maroc, Bank Al-Maghrib impose des exigences strictes de gestion du risque de crédit.

Un modèle de défaut bien calibré peut réduire le taux de créances douteuses de 20 à 40%.

Ce projet illustre une application ML à fort impact métier et financier direct.

2. OBJECTIFS DU PROJET

Objectifs pédagogiques

A l'issue de ce projet, vous serez capables de :

1. Explorer et nettoyer un dataset financier réel (valeurs manquantes, doublons, aberrants).
2. Appliquer le feature engineering : encodage et normalisation sur des variables mixtes.
3. Entraîner et évaluer un modèle de regression (Linear Regression) pour prédire un montant.
4. Entraîner et comparer 4 modèles de classification pour la détection du risque de défaut.
5. Comprendre et justifier le choix des métriques dans un contexte financier (Recall, Precision).
6. Analyser le déséquilibre de classes et ses implications pour les modèles de crédit.
7. Produire une analyse métier cohérente et des recommandations actionnables.

Objectifs techniques

- Maîtriser pandas, sklearn, matplotlib et seaborn pour un pipeline ML complet.
- Implémenter correctement la validation croisée (cross-validation) a 5 folds.
- Interpréter les matrices de confusion et les classification reports.
- Relier les résultats techniques aux enjeux métier du secteur bancaire.

3. DESCRIPTION DU DATASET

Fichier : credits_bancaires.csv

Taille : 612 lignes x 16 colonnes

Chaque ligne représente une demande de crédit soumise par un client. Le dataset contient délibérément des valeurs manquantes (~35 cellules réparties sur 5 colonnes) et des doublons (~12 lignes) pour simuler des conditions réalistes de collecte de données bancaires.

Colonne	Type	Description
id	Numérique (int)	Identifiant unique de la demande
age	Numérique (int)	Age du demandeur (22 à 65 ans)
genre	Catégorielle	Homme / Femme
ville	Catégorielle	Casablanca, Rabat, Tanger, Fes, Marrakech, Agadir, Meknès
situation_familiale	Catégorielle	Celibataire, Marié, Divorce, Veuf
niveau_education	Catégorielle (ord.)	Bac, Bac+2, Bac+3, Bac+5
secteur_activite	Catégorielle	Privé, Public, Indépendant, Sans emploi
anciennete_emploi_ans	Numérique (int)	Années d'ancienneté dans l'emploi actuel (* manquants)
revenu_mensuel_mad	Numérique (float)	Revenu mensuel net en MAD (* valeurs manquantes)
nb_dependants	Numérique (int)	Nombre de personnes à charge (* valeurs manquantes)
historique_credit	Catégorielle	Bon, Moyen, Mauvais (* valeurs manquantes)
nb_credits_precedents	Numérique (int)	Nombre de crédits antérieurs
ratio_endettement	Numérique (float)	Part du revenu déjà engagé en remboursements (* manquants)
duree_credit_mois	Numérique (int)	Durée demandée pour le credit (en mois)
montant_credit_mad	Numérique (float)	CIBLE (Regression) : Montant du crédit accordé en MAD
defaut_paiement	Binaire (0/1)	CIBLE (Classification) : 1 = défaut, 0 = remboursement normal

Distribution de la variable cible classification — defaut_paiement

defaut_paiement = 0 (Remboursement normal) : ~269 clients (44.0%)

defaut_paiement = 1 (Défaut de paiement) : ~343 clients (56.0%)

=> Desequilibre modere : analyser les métriques par classe avec soin.

=> Dans le contexte bancaire, le coût d'un Faux Négatif est TRÈS ÉLEVÉ.

=> Le Recall pour la classe 1 est la métrique prioritaire de ce projet.

Glossaire bancaire utile

Défaut de paiement : incapacité du client à rembourser le crédit selon l'échéancier convenu.

Ratio d'endettement : pourcentage du revenu mensuel déjà consacré aux remboursements existants.

Historique de crédit : note attribuée selon le comportement de remboursement passe du client.

Capacité de remboursement : part du revenu disponible pour un nouveau crédit (généralement <= 40%).

4. PARTIE 1 — EXPLORATION ET PRÉPARATION DES DONNÉES

4.1 Chargement et exploration initiale

Tâche 1.1 : Chargez le fichier CSV et affichez les premieres et dernieres lignes, les types de colonnes et un résumé statistique complet.

Tâche 1.2 : Calculez et visualisez le nombre de valeurs manquantes par colonne (graphique à barres). Quel pourcentage représentent-elles par rapport au total ?

Tâche 1.3 : Identifier et afficher les lignes dupliquées. Supprimez-les, puis vérifiez que le dataset est propre.

Tâche 1.4 : Analyser la distribution de défaut de defaut_paiement : proportions de chaque classe et visualisation avec un countplot annoté.

4.2 Analyse Exploratoire des Données (EDA)

Tâche 2.1 : Tracer la distribution du montant_credit_mad. Est-elle normale, asymétrique à droite (skewed), ou bimodale ? Quelles en sont les implications ?

Tâche 2.2 : Comparez la distribution du montant de crédit selon le secteur_activite et le niveau_education (boxplots). Que remarquez-vous ?

Tâche 2.3 : Affichez une heatmap de correlation. Quelles variables numériques sont les plus corrélées avec montant_credit_mad ?

Tâche 2.4 : Analyser le taux de défaut selon l'historique_credit, le ratio_endettement et le secteur_activite. Ces résultats sont-ils cohérents avec votre intuition ?

Tâche 2.5 : Tracez un scatter plot revenu_mensuel_mad vs montant_credit_mad en colorant les points selon defaut_paiement. Y a-t-il une séparation visible ?

4.3 Nettoyage des données

Tâche 3.1 : Remplacez les valeurs manquantes des colonnes numériques (anciennete_emploi_ans, revenu_mensuel_mad, nb_dependants, ratio_endettement) par leur mediane.

Tâche 3.2 : Remplacez les valeurs manquantes de la colonne catégorielle historique_credit par le mode (valeur la plus fréquente).

Tâche 3.3 : Vérifiez l'absence totale de valeurs manquantes apres nettoyage (df.isnull().sum().sum() == 0).

Tâche 3.4 : Détectez les valeurs aberrantes : clients avec revenu < 0, ratio_endettement > 1, ou âge hors de [18, 70]. Comptez-les et décidez de la stratégie à adopter.

4.4 Feature Engineering

Tâche 4.1 — Encodage : Appliquez le Label Encoding aux variables : genre, ville, situation_familiale, niveau_education, secteur_activite, historique_credit.

Tâche 4.2 — Normalisation : Appliquez StandardScaler sur : age, anciennete_emploi_ans, revenu_mensuel_mad, nb_dependants, nb_credits_precedents, ratio_endettement, duree_credit_mois.

Tâche 4.3 — Nouvelle feature (Bonus) : Calculez capacite_remboursement = revenu_mensuel_mad * (0.40 - ratio_endettement). Cette variable represente le budget disponible pour un nouveau credit.

Tache 4.4 — Nouvelle feature (Bonus) : Créez une variable risque_score = nb_credits_precedents * ratio_endettement. Analysez sa correlation avec defaut_paiement.

Pipeline de preprocessing recommande

1. Supprimer les doublons
2. Traiter les valeurs manquantes (mediane pour numériques, mode pour catégorielles)
3. Identifier et traiter les valeurs aberrantes
4. Créer les nouvelles features (feature engineering)
5. Encoder les variables catégorielles (LabelEncoder)
6. Normaliser les variables numériques (StandardScaler)
7. Séparer X (features) et y (cible)
8. Diviser en train / test (train_test_split, 80/20, stratify=y pour la classification)

5. PARTIE 2 — RÉGRESSION : Estimation du Montant de Crédit

Objectif métier : Déterminer automatiquement le montant de crédit optimal accordé à un client en fonction de son profil financier et personnel, afin de maximiser l'octroi tout en minimisant l'exposition au risque.

5.1 Préparation pour la regression

Tâche 5.1 : Définissez X (features) et y = montant_credit_mad. Excluez defaut_paiement et id du jeu de features.

Tâche 5.2 : Divisez en train (80%) et test (20%) avec random_state=42.

Tâche 5.3 : Justifiez pourquoi on doit appliquer le scaler après le split (et non avant) pour éviter le data leakage.

5.2 Modelisation — Linear Regression

Tâche 6.1 : Importez, instanciez et entraîner LinearRegression.

Tâche 6.2 : Effectuez les prédictions sur X_test.

Tâche 6.3 : Calculez et affichez : MAE, MSE, RMSE et R^2.

5.3 Validation croisée

Tâche 7.1 : Appliquez cross_val_score avec cv=5 et scoring='r2'. Affichez scores, moyenne et ecart-type.

Tâche 7.2 : Calculez aussi le R^2 sur le jeu d'entraînement. Comparez-le au R^2 test et au R^2 cross-validation.

5.4 Questions d'analyse — Régression

Question R1 : Interprétez le R^2 obtenu sur le jeu de test. Qualifiez la performance : excellent (>0.85), bon (0.70-0.85), moyen (0.50-0.70), insuffisant (<0.50) ?

Question R2 : Le RMSE obtenu est-il acceptable pour une banque ? Si le RMSE est de 50 000 MAD sur un crédit moyen de 200 000 MAD, que cela signifie-t-il opérationnellement ?

Question R3 : Comparez le R^2 entrainement vs R^2 test vs R^2 cross-validation. Y a-t-il de l'overfitting ? Comment le détecte-t-on ?

Question R4 : En vous basant sur la heatmap de corrélation de l'EDA, quelles variables sont les plus prédictives du montant de crédit ? Est-ce cohérent avec la logique bancaire ?

Question R5 : Tracez le graphique 'Montants réels vs Montants prédits'. Observez les points éloignés de la diagonale y=x : pour quels profils clients le modèle se trompe-t-il le plus ?

Question R6 (Bonus) : Analysez les résidus : tracez leur distribution et un scatter plot residus vs valeurs prédites. Le modèle présente-t-il de l'hétéroscédasticité ? Qu'est-ce que cela implique ?

6. PARTIE 3 — CLASSIFICATION : Détection du Risque de Défaut

Objectif métier : Identifier automatiquement les clients susceptibles de ne pas rembourser leur crédit (defaut_paiement = 1) avant l'octroi du prêt, afin de protéger la banque des pertes financières.

6.1 Préparation pour la classification

Tâche 8.1 : Définissez X (mêmes features) et y = defaut_paiement. Excluez montant_credit_mad et id.

Tâche 8.2 : Utilisez stratify=y dans train_test_split pour garantir la même proportion de défauts dans train et test.

Tâche 8.3 : Vérifiez et affichez la proportion de defaut_paiement dans X_train et X_test. Sont-elles cohérentes avec le dataset global ?

6.2 Entraînement des 4 modèles de classification

Modèle	Classe sklearn	Paramètres
Support Vector Machine	sklearn.svm.SVC	kernel='rbf', random_state=42
K-Nearest Neighbors	sklearn.neighbors.KNeighborsClassifier	n_neighbors=5
Decision Tree	sklearn.tree.DecisionTreeClassifier	random_state=42
Random Forest	sklearn.ensemble.RandomForestClassifier	n_estimators=100, random_state=42

Tâche 9.1 : Entraîner les 4 modèles et calculer pour chacun : Accuracy, Precision, Recall, F1-score (macro average).

Tâche 9.2 : Afficher le classification_report complet pour chaque modèle (précision, recall, f1 par classe).

Tâche 9.3 : Construire un tableau de synthèse comparant les 4 modèles sur toutes les métriques.

Tâche 9.4 : Afficher et commenter la matrice de confusion de chaque modèle.

6.3 L'enjeu financier des erreurs de prédiction

Analyse coût-bénéfice des erreurs — Contexte Credit Bancaire

FAUX NÉGATIF (FN) : le modèle prédit 'pas de défaut' mais le client fait défaut.
=> La banque accorde le crédit. Le client ne rembourse pas.
=> Perte financière directe pour la banque (montant du crédit non recouvre).
=> COÛT TRÈS ÉLEVÉ : c'est l'erreur la plus dangereuse.

FAUX POSITIF (FP) : le modèle prédit 'défaut' mais le client aurait remboursé.
=> La banque refuse le crédit à un bon client.
=> Manque à gagner (intérêts non perçus) et risque de perte de client.
=> COÛT MODÉRÉ.

=> La banque doit MAXIMISER le RECALL (classe 1) pour minimiser les FN.
=> Un Recall élevé signifie qu'on détecte un maximum de vrais clients à risque.

Tâche 10.1 : Pour chaque modèle, extrayez le Recall spécifique pour la classe 1 (défaut). Quel modèle est le plus performant sur ce critère ?

Tâche 10.2 : Comptez le nombre de Faux Négatifs (FN) dans la matrice de confusion de chaque modèle.

Tâche 10.3 : Si le montant moyen d'un crédit est 150 000 MAD et que le taux de perte en cas de défaut est 70%, estimer la perte financière totale générée par les FN de chaque modèle.

6.4 Validation croisée

Tâche 11.1 : Appliquez cross_val_score (cv=5, scoring='recall_macro') pour les 4 modèles.

Tâche 11.2 : Afficher la moyenne et l'ecart-type des scores. Quel modèle est le plus stable ?

Tâche 11.3 : Identifiez les modèles qui surapprentissent (overfitting) en comparant les scores d'entrainement vs validation croisée.

6.5 Questions d'analyse — Classification

Question C1 : Quel est le meilleur modèle selon le F1-score macro ? Et selon le Recall pour la classe 1 ? Les conclusions sont-elles identiques ?

Question C2 : Pourquoi une Accuracy de 70% peut être insuffisante pour un modèle de crédit ? Dans quels cas l'Accuracy peut-elle être trompeuse ?

Question C3 : Analysez le Decision Tree vs le Random Forest : le Decision Tree surapprentit-il ? Expliquez pourquoi le Random Forest est généralement plus robuste.

Question C4 : D'après la classification_report, pour quelle classe (0 ou 1) les modèles sont-ils les plus précis ? Pourquoi est-ce cohérent avec les données ?

Question C5 : En utilisant feature_importances_ du Random Forest, quelles sont les 3 variables les plus importantes pour prédire le défaut ? Est-ce cohérent avec l'EDA ?

Question C6 : Quelle métrique recommanderiez-vous à la direction bancaire comme KPI principal pour évaluer ce modèle en production ? Justifiez.

Question C7 : Estimer la perte financière totale évitée par le meilleur modèle par rapport a une décision aléatoire (sans modèle ML). Quel est le ROI potentiel de ce projet ?

Question C8 (Bonus) : La banque souhaite réduire encore les FN. Sans toucher aux hyperparamètres, quelle modification simple pourrait améliorer le Recall du Random Forest ?

7. PARTIE 4 — VISUALISATIONS RECOMMANDÉES

Intégrez ces visualisations dans votre notebook pour enrichir votre analyse et rendre vos conclusions plus percutantes.

Exploration des données (EDA)

- Histogramme du montant_credit_mad avec courbe KDE
- Boxplot du montant de crédit par secteur_activite et niveau_education
- Heatmap des corrélations entre toutes les variables numériques
- Countplot annoté de defaut_paiement (avec pourcentages)
- Barplot du taux de défaut par historique_credit (croissant)
- Scatter plot : revenu_mensuel_mad vs montant_credit_mad, colore par defaut_paiement

Régression

- Scatter plot 'Montants réels vs Montants prédits' avec droite y=x
- Histogramme de distribution des résidus avec courbe normale théorique
- Scatter plot des résidus vs valeurs prédites (test d'hétéroscédasticité)

Classification

- Heatmap de la matrice de confusion pour les 4 modèles (2x2 subplot)
- Bar chart comparatif : F1-score macro, Recall (classe 1) et Accuracy dès 4 modèles
- Bar chart des feature importances du Random Forest (top 10 variables)
- Graphique comparatif des pertes financières estimées par modèle (FN x coût)

8. PISTES D'AMÉLIORATION (Réflexion Critique)

Réflexion approfondie attendue. Aucune implémentation requise, mais des arguments détaillés sont nécessaires.

- Comment class_weight='balanced' pourrait-il améliorer le Recall sans modifier les hyperparamètres ?
- Quels hyperparamètres du Random Forest (max_depth, min_samples_split) pourraient réduire l'overfitting ?
- Quel impact aurait l'ajout de données macroéconomiques (taux directeur, inflation) sur le modèle ?
- Pourquoi un modèle de Logistic Regression serait-il plus interprétable et potentiellement préféré par la direction bancaire ?
- Proposer 2 nouvelles features qui pourraient améliorer la prédiction (ex : revenu_par_dependant, score_stabilite_emploi).

9. LIVRABLES & CRITÈRES D'ÉVALUATION

9.1 Ce que vous devez rendre

- Un notebook Jupyter (.ipynb) propre, structure et commente (cellules Markdown obligatoires).
- Le fichier credits_bancaires.csv (tel que fourni ou modifié après nettoyage).

9.2 Structure attendue du notebook

8. Cellule titre + contexte métier bancaire
9. Chargement, exploration et EDA (avec visualisations)
10. Nettoyage (manquants, doublons, aberrants)
11. Feature Engineering (encodage, normalisation, nouvelles features)
12. Regression — Linear Regression + 4 metriques + cross-validation
13. Classification — 4 modèles + classification_report + analyse FN
14. Validation croisée de la classification
15. Visualisations (minimum 8 graphiques)
16. Réponses détaillées aux questions (R1-R6, C1-C8)
17. Conclusion metier : recommandations pour la banque

Consignes importantes

Ne pas utiliser GridSearchCV, RandomizedSearchCV ou tout autre tuning hyperparamètres.

Utiliser random_state=42 partout pour garantir la reproductibilité.

Utiliser stratify=y dans train_test_split pour la partie classification.

Répondre à TOUTES les questions (R1-R6 et C1-C8) dans des cellules Markdown.

Chaque graphique doit avoir un titre, des axes labellisés et une interprétation en commentaire.

Les bibliothèques autorisées : pandas, numpy, sklearn, matplotlib, seaborn.